การเปรียบเทียบประสิทธิภาพและเวลาในการฝึก **EfficientNetB0, ResNet50** และ **DenseNet121** สำหรับการจำแนกโรคใบข้าวด้วยการถ่ายโอนการเรียนรู้และการเลือกจำนวนรอบการฝึกโดยการหยุดก่อนกำหนด

Performance and Training-Time Comparison of EfficientNetB0, ResNet50, and DenseNet121 for Rice Leaf Disease Classification Using Transfer Learning and Early-Stopping-Based Epoch Selection

ไก้รุ่ง เฮงพระพรหม (Kairung Hengpraprohm)* ณิชพน ธนวัตณัชกุล (Nichapon Thanawatnatchakul)* และ สุพจน์ เฮงพระพรหม (Supoj Hengpraprohm)*

* ผู้นิพนธ์ประสานงาน: สุพจน์ เฮงพระพรหม (Supoj Hengpraprohm) อีเมล: supojn@yahoo.com

บทคัดย่อ

งานวิจัยนี้มีวัตถุประสงค์เพื่อเปรียบเทียบประสิทธิภาพและเวลาในการฝึกของแบบจำลองการเรียนรู้เชิงลึก 3 สถาปัตยกรรม ได้แก่ EfficientNetB0, ResNet50 และ DenseNet121 สำหรับการจำแนกภาพใบข้าว 4 ประเภท ได้แก่ โรคใบไหม้จากแบคทีเรีย โรคใบจุดสีน้ำตาล โรคไหม้ และใบข้าวปกติ โดยใช้ข้อมูลจำนวน 2,569 ภาพ และประยุกต์ใช้การถ่ายโอนการเรียนรู้ด้วยค่าน้ำหนักจาก ImageNet พร้อมตรึงค่าน้ำหนักของโครงข่ายส่วนฐานทั้งหมด ขั้นตอนแรกใช้การหยุดก่อนกำหนดเพื่อหาจำนวนรอบการฝึกที่เหมาะสม โดยกำหนดจำนวนรอบที่รอเท่ากับ 10 และทดลองซ้ำ 10 ครั้งต่อแบบจำลอง ได้จำนวนรอบการฝึกที่เลือกใช้เท่ากับ 86, 59 และ 79 รอบ ตามลำดับ จากนั้นฝึกแบบจำลองด้วยข้อมูลร้อยละ 80 และประเมินด้วยชุดทดสอบร้อยละ 20 โดยทำซ้ำ 5 ครั้ง ผลการทดลองพบว่า EfficientNetB0 ให้ค่าความถูกต้องเฉลี่ยสูงสุดที่ร้อยละ 93.94 ± 0.23 รองลงมาคือ ResNet50 ร้อยละ 93.82 ± 0.82 และ DenseNet121 ร้อยละ 89.85 ± 0.75 เมื่อยืนยันผลด้วยการตรวจสอบไขว้แบบแบ่งชั้น 5 ส่วน พบว่า ResNet50 ให้ค่าความถูกต้องสูงสุดที่ร้อยละ 94.43 ± 1.12 รองลงมาคือ EfficientNetB0 ร้อยละ 94.32 ± 0.51 และ DenseNet121 ร้อยละ 90.31 ± 1.26 ในด้านเวลา EfficientNetB0 ใช้เวลาเฉลี่ยต่อรอบต่ำที่สุดประมาณ 0.47 นาที ขณะที่ ResNet50 ใช้จำนวนรอบในการลู่เข้าน้อยที่สุด สรุปได้ว่า EfficientNetB0 และ ResNet50 มีประสิทธิภาพใกล้เคียงกัน โดยการเลือกใช้งานควรพิจารณาร่วมกันทั้งความถูกต้อง ความเสถียร และเวลาในการฝึก

คำสำคัญ: การจำแนกโรคใบข้าว, การเรียนรู้เชิงลึก, การถ่ายโอนการเรียนรู้, การหยุดก่อนกำหนด, EfficientNetB0, ResNet50, DenseNet121

Abstract

This study aimed to compare the classification performance and training time of three deep learning architectures, namely EfficientNetB0, ResNet50, and DenseNet121, for classifying rice leaf images into four categories: Bacterial Leaf Blight, Brown Spot, Leaf Blast, and Healthy Rice Leaf. A total of 2,569 images were used, and transfer learning was applied using ImageNet-pretrained weights with all backbone layers frozen. In the first stage, early stopping was employed to determine the appropriate number of training epochs, with a patience value of 10. Each model was trained repeatedly for 10

*ภาควิชา---------- คณะ---------- มหาวิทยาลัย----------

* Department ----------, Faculty of ----------, University----------.

**ภาควิชา---------- คณะ---------- มหาวิทยาลัย----------

** Department ----------, Faculty of ----------, University----------.

runs, resulting in selected epoch values of 86, 59, and 79 for EfficientNetB0, ResNet50, and DenseNet121, respectively. The models were then trained using 80% of the dataset and evaluated on the remaining 20% test set over five repeated runs. EfficientNetB0 achieved the highest mean test accuracy of 93.94% ± 0.23%, followed by ResNet50 at 93.82% ± 0.82% and DenseNet121 at 89.85% ± 0.75%. Stratified 5-fold cross-validation further confirmed the results, with ResNet50 achieving the highest mean accuracy of 94.43% ± 1.12%, followed by EfficientNetB0 at 94.32% ± 0.51% and DenseNet121 at 90.31% ± 1.26%. In terms of training time, EfficientNetB0 required the lowest average time per epoch at approximately 0.47 minutes, whereas ResNet50 required the fewest epochs to reach the selected training point. Overall, EfficientNetB0 and ResNet50 demonstrated comparable performance. Therefore, model selection should consider classification accuracy, stability, and training efficiency together.

Keyword: Rice Leaf Disease Classification, Deep Learning, Transfer Learning, Early Stopping, EfficientNetB0, ResNet50, DenseNet121

1. บทนำ

ข้าวถือได้ว่าเป็นทั้งพืชอาหารและพืชเศรษฐกิจที่มีความสำคัญต่อประเทศไทยมาอย่างยาวนาน ทั้งในด้านความมั่นคงทางอาหาร เป็นแหล่งรายได้ของเกษตรกรและแหล่งเศรษฐกิจของประเทศจากการส่งออกสินค้าเกษตร [1] อย่างไรก็ตาม การผลิตข้าวในปัจจุบันยังต้องเผชิญกับปัจจัยหลายด้านที่อาจส่งผลกระทบต่อปริมาณและคุณภาพของผลผลิต ไม่ว่าจะเป็นความแปรปรวนของสภาพภูมิอากาศ สภาพแวดล้อมในการเพาะปลูก ตลอดจนโรคและศัตรูพืช โดยเฉพาะโรคที่ปรากฏอาการบนใบข้าว ซึ่งหากไม่สามารถตรวจพบและจำแนกโรคได้อย่างถูกต้องในระยะเริ่มต้น อาจทำให้การจัดการและควบคุมโรคล่าช้า ส่งผลต่อการเจริญเติบโตและผลผลิตของข้าวได้

โรคที่เกิดกับใบข้าวมีหลายชนิดและแสดงลักษณะอาการแตกต่างกัน อย่างไรก็ตาม การจำแนกโรคจากลักษณะที่ปรากฏบนใบด้วยการสังเกตของมนุษย์อาจมีข้อจำกัด เนื่องจากรอยโรคบางชนิดมีลักษณะทางกายภาพใกล้เคียงกัน โดยเฉพาะในบางระยะของการเกิดโรค ส่งผลให้ต้องอาศัยผู้ที่มีประสบการณ์ในการวินิจฉัย [2] งานวิจัยนี้จึงมุ่งเน้นการจำแนกภาพใบข้าวใน 4 ลักษณะ ได้แก่ โรคใบไหม้จากแบคทีเรีย (Bacterial Leaf Blight) โรคใบจุดสีน้ำตาล (Brown Spot) โรคไหม้ (Leaf Blast) และใบข้าวปกติ (Healthy Rice Leaf)

ความก้าวหน้าของปัญญาประดิษฐ์ โดยเฉพาะการเรียนรู้เชิงลึก (Deep Learning) และโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) [2]-[4] ทำให้การวิเคราะห์ภาพเพื่อจำแนกโรคพืชสามารถดำเนินการได้อย่างมีประสิทธิภาพมากขึ้น โมเดล CNN สามารถเรียนรู้คุณลักษณะของภาพตั้งแต่ลักษณะพื้นฐาน เช่น ขอบ สี และพื้นผิว ไปจนถึงคุณลักษณะที่มีความซับซ้อนในระดับสูงได้โดยอัตโนมัติ ขณะเดียวกัน การถ่ายโอนการเรียนรู้ (Transfer Learning) ทำให้สามารถนำโมเดลที่ผ่านการฝึกจากชุดข้อมูลภาพขนาดใหญ่มาปรับใช้กับงานจำแนกโรคพืชที่มีข้อมูลจำกัดได้

งานวิจัยของ Too และคณะ [3] ได้เปรียบเทียบโมเดลการเรียนรู้เชิงลึกหลายสถาปัตยกรรมสำหรับการจำแนกโรคพืช ได้แก่ VGG16, Inception-V4, ResNet50, ResNet101, ResNet152 และ DenseNet121 โดยใช้ข้อมูล PlantVillage จำนวน 38 คลาส ผลการศึกษาแสดงให้เห็นว่าสถาปัตยกรรมการเรียนรู้เชิงลึกที่แตกต่างกันจะทำให้ทั้งประสิทธิภาพ จำนวนพารามิเตอร์ และพฤติกรรมการเรียนรู้แตกต่างกัน ซึ่งสะท้อนให้เห็นถึงความสำคัญของการเลือกสถาปัตยกรรมโมเดลให้เหมาะสมก่อนนำไปประยุกต์ใช้งานจริง นอกจากนี้ โมเดลกลุ่ม EfficientNet อย่างเช่น EfficientNetB0 ถือว่าเป็นสถาปัตยกรรมที่ถูกออกแบบมาให้มีความแม่นยำสูงในขณะที่ใช้พารามิเตอร์และการคำนวณที่น้อยกว่า จึงเป็นโมเดลที่เหมาะกับการนำไปใช้งานจริงบนอุปกรณ์ที่มีทรัพยากรจำกัด [5]

จากการศึกษาของ Seelwal และคณะ [4] ซึ่งรวบรวมงานวิจัยด้านการเรียนรู้เชิงลึก สำหรับการวินิจฉัยโรคข้าว พบว่า โมเดล CNN และการถ่ายโอนการเรียนรู้เชิงลึก (Deep Transfer Learning) ได้ถูกนำมาใช้เพิ่มขึ้นอย่างต่อเนื่องในการตรวจหาและจำแนกโรคข้าว รวมถึงโรคใบไหม้จากแบคทีเรีย โรคใบจุดสีน้ำตาล และโรคไหม้ โดยมีประสิทธิภาพในการสนับสนุนระบบตรวจวินิจฉัยโรคข้าวแบบอัตโนมัติ อย่างไรก็ตาม การเลือกสถาปัตยกรรมที่เหมาะสมไม่ควรพิจารณาเฉพาะค่าความแม่นยำในการจำแนกเท่านั้น แต่ควรพิจารณาต้นทุนด้านการคำนวณและลักษณะการเรียนรู้ของโมเดลร่วมด้วย

ด้วยเหตุนี้ งานวิจัยนี้จึงมุ่งเปรียบเทียบประสิทธิภาพและเวลาในการฝึก EfficientNetB0, ResNet50 และ DenseNet121 สำหรับการจำแนกโรคใบข้าว 4 ประเภท โดยประยุกต์ใช้การถ่ายโอนการเรียนรู้และใช้การหยุดก่อนกำหนด (Early Stopping) เพื่อหาจำนวนรอบการฝึกที่เหมาะสมของแต่ละโมเดล ก่อนนำค่าที่ได้ไปใช้ในการประเมินประสิทธิภาพภายใต้เงื่อนไขเดียวกัน เพื่อให้การเปรียบเทียบครอบคลุมทั้งทางด้านประสิทธิภาพในการจำแนกและประสิทธิภาพด้านเวลาในการฝึก

2. ทฤษฎีที่เกี่ยวข้อง

2.1 การเรียนรู้เชิงลึกและสถาปัตยกรรมโมเดลที่ใช้ในงานวิจัย

การเรียนรู้เชิงลึกเป็นเทคนิคหนึ่งของการเรียนรู้ของเครื่องที่ใช้โครงข่ายประสาทเทียมหลายชั้นในการเรียนรู้รูปแบบและคุณลักษณะจากข้อมูลโดยอัตโนมัติ สำหรับงานด้านการวิเคราะห์ภาพ โครงข่ายประสาทเทียมแบบคอนโวลูชัน (CNN) เป็นสถาปัตยกรรมที่ได้รับการนำมาใช้อย่างแพร่หลาย เนื่องจากสามารถเรียนรู้คุณลักษณะเชิงพื้นที่ของภาพได้ตั้งแต่ระดับพื้นฐาน เช่น ขอบ สี และพื้นผิว ไปจนถึงคุณลักษณะที่มีความซับซ้อนมากขึ้น โดยทั่วไป CNN ประกอบด้วยชั้นคอนโวลูชันสำหรับสกัดคุณลักษณะ ชั้นพูลลิงสำหรับลดขนาดข้อมูล และชั้นจำแนกประเภทสำหรับทำนายผลลัพธ์ในขั้นสุดท้าย แนวทางดังกล่าวเหมาะกับการจำแนกโรคพืชจากภาพ เนื่องจากสามารถเรียนรู้ลักษณะของรอยโรคที่แตกต่างกันจากข้อมูลภาพโดยตรง

งานวิจัยนี้เลือกใช้สถาปัตยกรรม CNN จำนวน 3 รูปแบบ ได้แก่ EfficientNetB0, ResNet50 และ DenseNet121 ซึ่งมีแนวคิดการออกแบบแตกต่างกัน ซึ่งมีรายละเอียดดังนี้

1) EfficientNetB0 พัฒนาโดย Tan และ Le [5] โดยใช้แนวคิดการปรับขนาดเครือข่ายแบบผสมผสาน (Compound Scaling) ซึ่งปรับความลึกของโครงข่าย ความกว้างของโครงข่าย และความละเอียดของภาพอย่างสมดุล ทำให้สามารถเพิ่มประสิทธิภาพของโมเดลโดยไม่เพิ่มภาระการคำนวณมากเกินความจำเป็น จุดเด่นของ EfficientNetB0 คือมีจำนวนพารามิเตอร์และความซับซ้อนในการคำนวณค่อนข้างต่ำเมื่อเทียบกับโมเดลที่ให้ประสิทธิภาพใกล้เคียงกัน จึงเหมาะสำหรับงานที่ต้องคำนึงถึงทั้งความถูกต้องและประสิทธิภาพด้านทรัพยากร

2) ResNet50 พัฒนาโดย He และคณะ [6] โดยมีจุดเด่นคือการใช้ การเชื่อมต่อแบบข้ามชั้น (Residual Connection หรือ Skip Connection) ซึ่งอนุญาตให้ข้อมูลจากชั้นก่อนหน้าสามารถส่งผ่านไปยังชั้นที่ลึกกว่าได้โดยตรง แนวทางนี้ช่วยลดปัญหาการหายไปของค่าความชัน (Vanishing Gradient) และทำให้สามารถฝึกโครงข่ายที่มีความลึกมากขึ้นได้อย่างมีประสิทธิภาพ

3) DenseNet121 พัฒนาโดย Huang และคณะ [7] ใช้แนวคิดการเชื่อมต่อแบบหนาแน่น (Dense Connection) โดยเชื่อมแต่ละชั้นเข้ากับชั้นก่อนหน้าหลายชั้นผ่านการรวมคุณลักษณะ ทำให้คุณลักษณะที่ถูกเรียนรู้สามารถนำกลับมาใช้ซ้ำได้ และช่วยส่งผ่านสารสนเทศและค่าความชัน (Gradient) ภายในโครงข่ายได้อย่างมีประสิทธิภาพ

แม้ทั้งสามสถาปัตยกรรมจะเป็นโครงข่าย CNN ที่สามารถประยุกต์ใช้กับงานจำแนกภาพได้ แต่ความแตกต่างด้านโครงสร้าง การเชื่อมต่อภายในโครงข่าย และจำนวนพารามิเตอร์อาจส่งผลต่อทั้งความสามารถในการจำแนก ความเร็วในการลู่เข้า และเวลาในการฝึก ดังนั้น งานวิจัยนี้จึงเลือก EfficientNetB0, ResNet50

และ DenseNet121 มาเปรียบเทียบภายใต้เงื่อนไขการทดลองเดียวกัน เพื่อศึกษาความแตกต่างทั้งด้านประสิทธิภาพในการจำแนกโรคใบข้าวและประสิทธิภาพด้านเวลาในการฝึก

2.2 การถ่ายโอนการเรียนรู้

การถ่ายโอนการเรียนรู้ (Transfer Learning) เป็นแนวทางการเรียนรู้ของเครื่องที่นำความรู้จากแบบจำลองซึ่งผ่านการเรียนรู้จากข้อมูลหรือภารกิจหนึ่ง มาใช้เป็นพื้นฐานในการเรียนรู้ภารกิจใหม่ที่มีความเกี่ยวข้องกัน แนวทางดังกล่าวช่วยลดการพึ่งพาข้อมูลจำนวนมากในงานเป้าหมาย และมีประโยชน์อย่างยิ่งในกรณีที่ชุดข้อมูลสอนมีจำนวนจำกัด [8] สำหรับงานด้านการจำแนกภาพมักนำแบบจำลองที่ผ่านการฝึกจากชุดข้อมูลภาพขนาดใหญ่มาใช้เป็นจุดเริ่มต้น เนื่องจากแบบจำลองดังกล่าวสามารถเรียนรู้คุณลักษณะทั่วไปของภาพ เช่น ขอบ รูปร่าง สี และพื้นผิว ซึ่งสามารถนำมาประยุกต์ใช้กับงานจำแนกภาพเฉพาะด้านได้

การประยุกต์ใช้การถ่ายโอนการเรียนรู้กับโครงข่ายประสาทเทียมเชิงลึกสามารถดำเนินการได้หลายรูปแบบ โดยแนวทางที่ใช้กันทั่วไป ได้แก่ การใช้แบบจำลองเป็นตัวสกัดคุณลักษณะ (Feature Extraction) ซึ่งตรึงค่าน้ำหนักของโครงข่ายส่วนฐานและฝึกเฉพาะชั้นจำแนกประเภทที่เพิ่มเข้ามาใหม่ และ การปรับแต่งแบบจำลองเพิ่มเติม (Fine-tuning) ซึ่งเปิดให้ค่าน้ำหนักบางส่วนหรือทั้งหมดของโครงข่ายเดิมสามารถปรับเปลี่ยนตามข้อมูลของงานเป้าหมายได้ ดังเช่นในงานของ Too และคณะ [3] แสดงให้เห็นว่าการนำแบบจำลองเชิงลึกที่ผ่านการฝึกมาก่อนมาปรับใช้กับการจำแนกโรคพืชสามารถให้ประสิทธิภาพสูง โดยได้เปรียบเทียบสถาปัตยกรรมหลายชนิด ได้แก่ VGG16, Inception-V4, ResNet และ DenseNet บนชุดข้อมูล PlantVillage

งานวิจัยนี้ใช้การถ่ายโอนการเรียนรู้ในลักษณะ การสกัดคุณลักษณะ โดยนำ EfficientNetB0, ResNet50 และ DenseNet121 ที่มีค่าน้ำหนักเริ่มต้นจากการฝึกด้วย ImageNet มาใช้ และตรึงค่าน้ำหนักของโครงข่ายส่วนฐานทั้งหมด (Freeze Backbone) จากนั้นฝึกเฉพาะส่วนจำแนกประเภทสำหรับจำแนกภาพใบข้าว 4 ประเภท วิธีการดังกล่าวทำให้สามารถเปรียบเทียบความสามารถของตัวสกัดคุณลักษณะจากสถาปัตยกรรมทั้งสามภายใต้เงื่อนไขการทดลองที่สอดคล้องกัน และลดผลกระทบจากการปรับค่าน้ำหนักของโครงข่ายส่วนฐานที่อาจแตกต่างกันในแต่ละแบบจำลอง

2.3 การหยุดก่อนกำหนดและการเลือกจำนวนรอบการฝึก

การหยุดก่อนกำหนด (Early Stopping) [9] เป็นเทคนิคที่ใช้ควบคุมกระบวนการฝึกแบบจำลองการเรียนรู้เชิงลึก โดยติดตามค่าประสิทธิภาพจากชุดข้อมูลตรวจสอบความถูกต้อง (Validation Set) ระหว่างการฝึก หากค่าที่ติดตามไม่มีการปรับปรุงตามจำนวนรอบที่กำหนด กระบวนการฝึกจะถูกยุติก่อนถึงจำนวนรอบสูงสุด แนวทางนี้ช่วยลดความเสี่ยงของการเกิดภาวะเรียนรู้มากเกินไป (Overfitting) และหลีกเลี่ยงการใช้เวลาและทรัพยากรในการฝึกเกินความจำเป็น โดยค่าที่นิยมใช้ในการติดตาม ได้แก่ ค่าความสูญเสียของชุดตรวจสอบความถูกต้อง (Validation Loss) เนื่องจากสามารถสะท้อนการเปลี่ยนแปลงของความผิดพลาดของแบบจำลองได้อย่างต่อเนื่อง

ในการประยุกต์ใช้ การหยุดก่อนกำหนด จำเป็นต้องกำหนดค่า จำนวนรอบที่รอ (Patience) ซึ่งหมายถึงจำนวนรอบที่ยอมให้ค่าที่ติดตามไม่ดีขึ้นก่อนหยุดการฝึก ดังนั้น รอบที่แบบจำลองหยุดฝึกจริงจึงอาจไม่ใช่รอบที่ให้ผลดีที่สุด ตัวอย่างเช่น หากกำหนดค่า Patience เท่ากับ 10 แบบจำลองจะยังคงฝึกต่ออีกระยะหนึ่งหลังจากพบค่าที่ดีที่สุด เพื่อรอตรวจสอบว่าค่าดังกล่าวจะสามารถปรับปรุงต่อได้หรือไม่ ด้วยเหตุนี้จึงควรแยกความหมายระหว่าง รอบการฝึกที่ดีที่สุด (Best Epoch) ซึ่งเป็นรอบที่ให้ค่าความสูญเสียของชุดตรวจสอบความถูกต้องต่ำที่สุด กับ รอบที่หยุดการฝึก (Stopped Epoch) ซึ่งเป็นรอบที่กลไกการหยุดก่อนกำหนด ยุติกระบวนการฝึก

งานวิจัยนี้ใช้การหยุดก่อนกำหนดโดยติดตามค่าความสูญเสียของชุดตรวจสอบความถูกต้องต่ำที่สุด

กำหนดค่า จำนวนรอบที่รอ เท่ากับ 10 และคืนค่าน้ำหนักของแบบจำลองจากรอบที่ให้ผลดีที่สุด จากนั้นทำการทดลองซ้ำจำนวน 10 ครั้งต่อแบบจำลอง เพื่อพิจารณาความแปรปรวนของจำนวนรอบการฝึกที่ดีที่สุดที่เกิดจากความสุ่มของกระบวนการฝึก แล้วนำค่ารอบการฝึกที่ดีที่สุดที่ได้มาหาค่าเฉลี่ยและปัดเป็นจำนวนเต็ม เพื่อกำหนดเป็นจำนวนรอบการฝึกคงที่ของ EfficientNetB0, ResNet50 และ DenseNet121 ในขั้นตอนการเปรียบเทียบประสิทธิภาพต่อไป แนวทางดังกล่าวช่วยให้แต่ละสถาปัตยกรรมได้รับจำนวนรอบการฝึกที่สอดคล้องกับพฤติกรรมการลู่เข้าของตนเอง แทนการกำหนดจำนวนรอบที่เท่ากันทุกแบบจำลอง ซึ่งอาจทำให้บางแบบจำลองถูกฝึกน้อยหรือมากเกินความเหมาะสม

3. วิธีดำเนินการวิจัย

3.1 ชุดข้อมูลและการเตรียมข้อมูล

ชุดข้อมูลที่ใช้ในการวิจัยนำมาจากชุดข้อมูลสาธารณะ Rice Disease Dataset บนแพลตฟอร์ม Kaggle ซึ่งชุดข้อมูลต้นฉบับประกอบด้วยภาพใบข้าวจำนวน 3,829 ภาพ แบ่งออกเป็น 6 ประเภท ได้แก่ Bacterial Leaf Blight, Brown Spot, Healthy Rice Leaf, Leaf Blast, Leaf Scald และ Sheath Blight [10] ในงานวิจัยนี้เลือกใช้เฉพาะ 4 ประเภทที่สอดคล้องกับขอบเขตการศึกษา ได้แก่ โรคใบไหม้จากแบคทีเรีย (Bacterial Leaf Blight) จำนวน 636 ภาพ โรคใบจุดสีน้ำตาล (Brown Spot) จำนวน 646 ภาพ โรคไหม้ (Leaf Blast) จำนวน 634 ภาพ และใบข้าวปกติ (Healthy Rice Leaf) จำนวน 653 ภาพ รวมทั้งสิ้น 2,569 ภาพ โดยแต่ละประเภทมีสัดส่วนระหว่างร้อยละ 24.68–25.42 ของข้อมูลที่นำมาใช้ ดังแสดงในตารางที่ 1 ซึ่งแสดงให้เห็นว่าข้อมูลทั้ง 4 ประเภทมีการกระจายตัวค่อนข้างสมดุล ตัวอย่างภาพใบข้าวแต่ละประเภท แสดงดังภาพที่ 1

ก่อนนำข้อมูลเข้าสู่กระบวนการฝึกโมเดล ภาพทั้งหมดถูกปรับขนาดเป็น 224 × 224 พิกเซล ให้สอดคล้องกับขนาดข้อมูลนำเข้าที่กำหนดในการทดลองของ EfficientNetB0, ResNet50 และ DenseNet121 จากนั้นปรับค่าพิกเซลด้วยฟังก์ชัน preprocess_input จากไลบรารีของ Tensorflow ในภาษาไพธอน ให้เหมาะสมกับแต่ละสถาปัตยกรรม เพื่อให้ข้อมูลมีรูปแบบสอดคล้องกับค่าน้ำหนักที่ผ่านการฝึกจากชุดข้อมูล ImageNet ซึ่งเป็นชุดข้อมูลภาพขนาดใหญ่ที่ใช้สำหรับฝึกโมเดลการเรียนรู้เชิงลึกล่วงหน้า เพื่อให้สามารถเรียนรู้คุณลักษณะทั่วไปของภาพ และนำมาใช้ในกระบวนการถ่ายโอนการเรียนรู้



ภาพที่ 1 ตัวอย่างภาพแต่ละประเภทในชุดข้อมูลที่ใช้ในการทดลอง

ตารางที่ 1 ชุดข้อมูลที่ใช้ในการทดลอง

ประเภทภาพใบข้าว	จำนวนภาพ	สัดส่วน (%)
Bacterial Leaf Blight	636	24.76
Brown Spot	646	25.15
Leaf Blast	634	24.68
Healthy Rice Leaf	653	25.42
รวม	2,569	100.00

การทดลองนี้ไม่ใช้เทคนิคการเพิ่มข้อมูล (Data Augmentation) เพื่อควบคุมเงื่อนไขในการเปรียบเทียบโมเดลทั้งสามให้เป็นไปในแนวทางเดียวกัน และมุ่งศึกษาประสิทธิภาพของสถาปัตยกรรมภายใต้ชุดข้อมูลเดียวกัน นอกจากนี้ เนื่องจากจำนวนภาพของแต่ละประเภทมีสัดส่วนใกล้เคียงกัน จึงไม่มีการปรับสมดุลจำนวนข้อมูลระหว่างประเภทข้อมูลเพิ่มเติมก่อนเข้าสู่กระบวนการทดลอง

3.2 การออบแบบการทดลอง

การทดลองนี้ออกแบบเพื่อเปรียบเทียบประสิทธิภาพและเวลาในการฝึกของแบบจำลอง EfficientNetB0, ResNet50 และ DenseNet121 ภายใต้

เงื่อนไขเดียวกัน โดยแบ่งชุดข้อมูลด้วยวิธีการสุ่มแบบคงสัดส่วนของแต่ละประเภท (Stratified Random Split) ในอัตราส่วน 60:20:20 สำหรับชุดข้อมูลสอน (Training Set) ชุดตรวจสอบความถูกต้อง (Validation Set) และชุดข้อมูลทดสอบ (Test Set) ตามลำดับ ชุดข้อมูลทดสอบร้อยละ 20 ถูกแยกออกตั้งแต่เริ่มต้นและไม่ถูกนำมาใช้ในกระบวนการเลือกจำนวนรอบการฝึก เพื่อป้องกันการนำข้อมูลทดสอบมาใช้ในการปรับแบบจำลองก่อนการประเมินผล

แบบจำลองทั้งสามใช้การถ่ายโอนการเรียนรู้ โดยกำหนดค่าน้ำหนักเริ่มต้นจากแบบจำลองที่ผ่านการฝึกด้วยชุดข้อมูล ImageNet และตรึงค่าน้ำหนักของโครงข่ายส่วนฐานทั้งหมด เพื่อให้ทำหน้าที่เป็นตัวสกัดคุณลักษณะ จากนั้นฝึกเฉพาะส่วนจำแนกประเภท โดยควบคุมพารามิเตอร์ในการทดลองให้เหมือนกันทุกแบบจำลอง ได้แก่ ขนาดภาพนำเข้า 224 × 224 พิกเซล ขนาดกลุ่มข้อมูล (Batch Size) เท่ากับ 32 อัตราการเรียนรู้เท่ากับ 1 x 10-3 ใช้ Adam เป็นตัวปรับค่าน้ำหนัก ฟังก์ชันความสูญเสียแบบ Categorical Cross-Entropy และฟังก์ชันกระตุ้นในชั้นผลลัพธ์แบบ Softmax ซึ่งพารามิเตอร์ที่ใช้แสดงได้ดังตารางที่ 2 และรายละเอียดสภาพแวดล้อมที่ใช้ในการทดลองแสดงดังตารางที่ 3

ตารางที่ 2 ค่าพารามิเตอร์ที่ใช้ในการทดลอง

พารามิเตอร์	ค่าที่ใช้ในการทดลอง
แบบจำลอง	EfficientNetB0, ResNet50, DenseNet121
ขนาดภาพ	224 × 224 พิกเซล
ค่าน้ำหนักเริ่มต้น	ImageNet
รูปแบบการถ่ายโอนการเรียนรู้	Freeze Backbone
Batch Size	32
Learning Rate	0.001
Optimizer	Adam
Loss Function	Categorical Cross-Entropy
Output Activation	Softmax
Early Stopping	ติดตาม Validation Loss
จำนวนรอบที่รอ (Patience)	10 รอบ

ตารางที่ 3 สภาพแวดล้อมที่ใช้ในการทดลอง

รายการ	รายละเอียด
แพลตฟอร์ม	Google Colab Free Tier
หน่วยประมวลผลกราฟิก (GPU)	NVIDIA Tesla T4 16 GB
หน่วยความจำ (RAM)	13.6 GB
เฟรมเวิร์ก	TensorFlow 2.20.0
เวอร์ชันของ Python	3.13.15
ไลบรารีหลัก	TensorFlow, NumPy, Pandas, scikit-learn, Matplotlib และ Seaborn

ในขั้นแรกจะดำเนินการเพื่อค้นหา จำนวนรอบการฝึกที่เหมาะสม (Best Epoch) ของแต่ละแบบจำลอง โดยใช้ชุดข้อมูลสอนร้อยละ 60 สำหรับการเรียนรู้ และชุดตรวจสอบความถูกต้องร้อยละ 20 สำหรับติดตามค่าความสูญเสียของชุดตรวจสอบความถูกต้อง (Validation Loss) กำหนดจำนวนรอบการฝึกสูงสุดไว้ที่ 1,000 รอบ และใช้การหยุดก่อนกำหนด โดยกำหนดจำนวนรอบที่รอเท่ากับ 10 รอบ ทั้งนี้ จำนวนรอบการฝึกที่เหมาะสมหมายถึงรอบที่ให้ค่าความสูญเสียของชุดตรวจสอบความถูกต้อง (Validation Loss) ต่ำที่สุด (ไม่ใช่รอบสุดท้ายที่กระบวนการฝึกถูกหยุด) การทดลองดังกล่าวจะถูกทำซ้ำ 10 ครั้งต่อแบบจำลอง แล้วนำจำนวนรอบการฝึกที่เหมาะสมทั้ง 10 ครั้งมาหาค่าเฉลี่ยและปัดเป็นจำนวนเต็ม เพื่อใช้เป็นจำนวนรอบการฝึกคงที่ของแต่ละแบบจำลองในขั้นตอนถัดไป

ขั้นที่สอง หลังจากได้จำนวนรอบการฝึกที่เหมาะสมแล้ว ชุดข้อมูลสอนและชุดตรวจสอบความถูกต้องถูกนำมารวมกัน (Train set + Validation set) รวมเป็น ร้อยละ 80 ของชุดข้อมูลทั้งหมด เพื่อเพิ่มปริมาณข้อมูลสำหรับการเรียนรู้ จากนั้นฝึกแบบจำลองใหม่ตั้งแต่ต้นด้วยจำนวนรอบการฝึกคงที่ที่ได้จากขั้นแรก โดยไม่ใช้การหยุดก่อนกำหนด และประเมินผลกับชุดทดสอบร้อยละ 20 ซึ่งไม่เคยถูกใช้ในการเลือกจำนวนรอบการฝึกมาก่อน กระบวนการนี้จะทำซ้ำด้วยค่าเริ่มต้นการสุ่มที่แตกต่างกันจำนวน 5 ครั้ง เพื่อประเมินความเสถียรของผลลัพธ์ โดยรายงานประสิทธิภาพในรูปค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน

ขั้นที่สาม ยืนยันผลและเปรียบเทียบเวลา โดยทำการตรวจสอบด้วยการตรวจสอบไขว้แบบแบ่งชั้น 5 ส่วน (Stratified 5-Fold Cross-Validation) และรายงานค่าความถูกต้อง (Accuracy) และเวลาเฉลี่ยที่ใช้ในแต่ละรอบการฝึกของแต่ละแบบจำลองเพื่อทำการเปรียบเทียบประสิทธิภาพด้านเวลาที่ใช้ในการฝึก

ภาพรวมของขั้นตอนการดำเนินการวิจัย แสดงได้ดังภาพที่ 2

4. ผลการดำเนินงาน

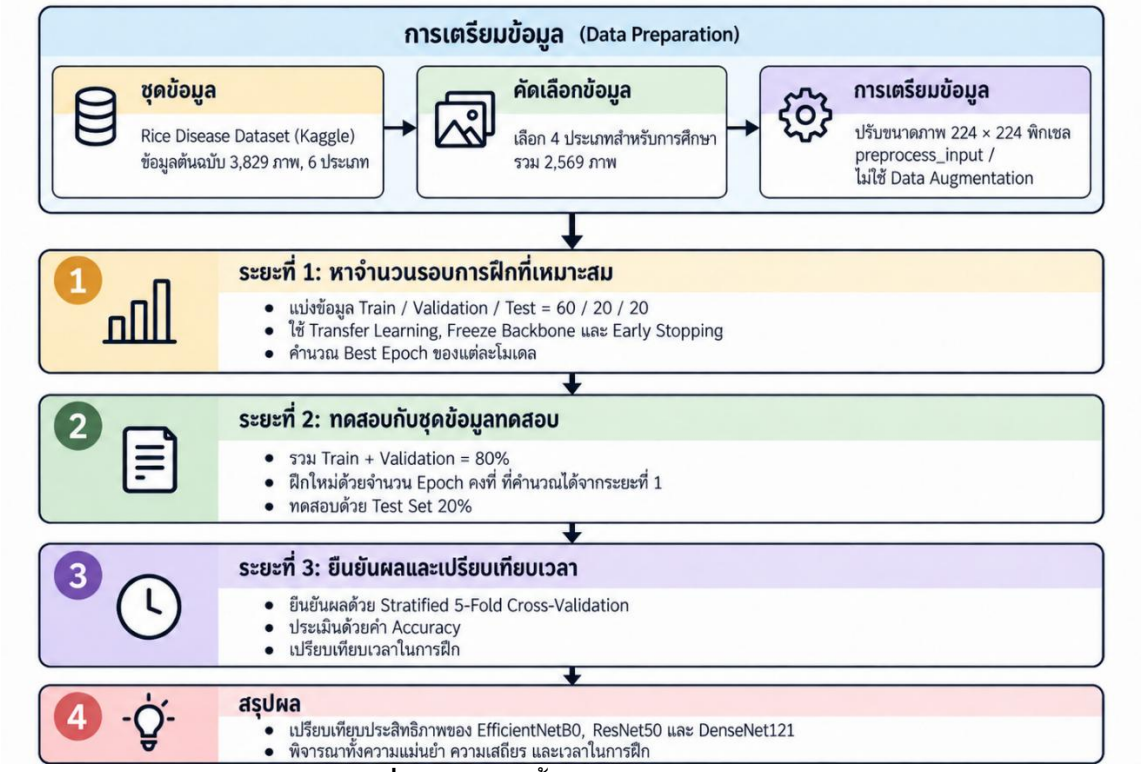
4.1 ผลการหาจำนวนรอบการฝึกที่เหมาะสม

การทดลองในขั้นตอนแรกมีวัตถุประสงค์เพื่อหาจำนวนรอบการฝึกที่เหมาะสม (Best Epoch) ของแบบจำลอง EfficientNetB0, ResNet50 และ DenseNet121 โดยใช้การหยุดก่อนกำหนด (Early Stopping) ซึ่งติดตามค่าความสูญเสียของชุดตรวจสอบความถูกต้อง (Validation Loss) และกำหนดจำนวนรอบที่รอ (Patience) เท่ากับ 10 รอบ การทดลองดำเนินการซ้ำจำนวน 10 ครั้งต่อแบบจำลอง จากนั้นนำค่า จำนวนรอบการฝึกที่เหมาะสมที่ได้มาคำนวณค่าเฉลี่ยและปัดเป็นจำนวนเต็มเพื่อใช้เป็นจำนวนรอบการฝึกคงที่ในขั้นตอนถัดไป ผลการทดลองแสดงได้ดังตารางที่ 4

ตารางที่ 4 ผลการหาจำนวนรอบการฝึกที่เหมาะสม (Best Epoch) ของแต่ละแบบจำลอง

แบบจำลอง	ค่าเฉลี่ย Best Epoch	SD	จำนวนรอบการฝึกที่เลือกใช้
EfficientNetB0	85.8	13.67	86
ResNet50	58.6	8.60	59
DenseNet121	79.4	7.70	79

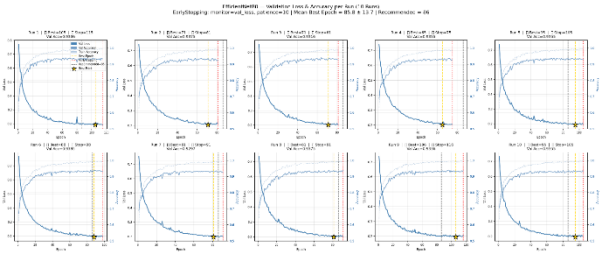
ผลการทดลองพบว่า ResNet50 ใช้จำนวนรอบการฝึกเฉลี่ยต่ำที่สุดที่ 58.6 รอบ และกำหนดเป็น 59 รอบสำหรับการทดลองขั้นต่อไป ขณะที่ DenseNet121 มีค่าเฉลี่ย 79.4 รอบ และ EfficientNetB0 มีค่าเฉลี่ยสูงที่สุดที่ 85.8 รอบ จึงกำหนดจำนวนรอบการฝึกเป็น 79 และ 86 รอบ ตามลำดับ ผลดังกล่าวแสดงให้เห็นว่าแบบจำลองแต่ละสถาปัตยกรรมมีพฤติกรรมการลู่เข้าที่แตกต่างกัน จึงสนับสนุนแนวทางการเลือกจำนวนรอบการฝึกให้เหมาะสมกับแต่ละแบบจำลอง แทนการกำหนดจำนวนรอบเท่ากันทุกสถาปัตยกรรม



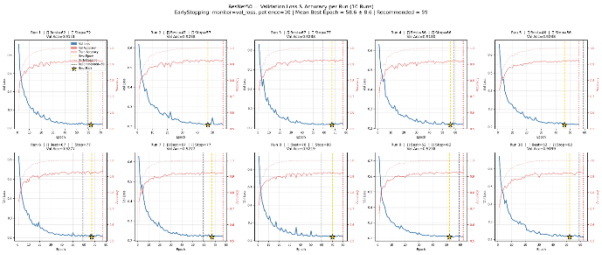
ภาพที่ 2 ภาพรวมขั้นตอนการดำเนินการวิจัย

4.2 การลู่เข้าของแบบจำลองระหว่างการฝึก

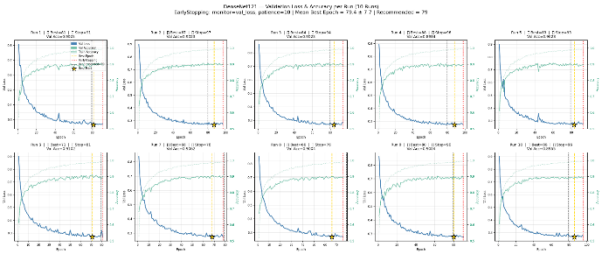
เพื่อพิจารณาพฤติกรรมการเรียนรู้ของแบบจำลอง จึงได้ทำการวิเคราะห์เส้นโค้งค่าความสูญเสียและค่าความถูกต้องของชุดข้อมูลสอนและชุดตรวจสอบความถูกต้องในแต่ละรอบการฝึก ดังแสดงในภาพที่ 3 – 5 สำหรับ EfficientNetB0, ResNet50 และ DenseNet121 ตามลำดับ



ภาพที่ 3 เส้นโค้งค่าความสูญเสียและความถูกต้องระหว่างการฝึกสอนของโมเดล EfficientNetB0



ภาพที่ 4 เส้นโค้งค่าความสูญเสียและความถูกต้องระหว่างการฝึกสอนของโมเดล ResNet50



ภาพที่ 5 เส้นโค้งค่าความสูญเสียและความถูกต้องระหว่างการฝึกสอนของโมเดล DenseNet121

จากเส้นโค้งการเรียนรู้พบว่าแบบจำลองทั้งสามมีค่าความสูญเสียของชุดตรวจสอบความถูกต้อง (Validation Loss) ลดลงในช่วงแรกจนถึงจุดต่ำสุด ก่อนมีแนวโน้มคงที่หรือเพิ่มขึ้นเล็กน้อยในช่วงหลัง ซึ่งเป็นสัญญาณว่าแบบจำลองเริ่มไม่สามารถเพิ่มประสิทธิภาพในการการฝึกเพิ่มเติม กลไกการหยุดก่อนกำหนดจึงช่วยระบุจุดที่เหมาะสมและคืนค่าน้ำหนักของแบบจำลองจากรอบที่มีค่าความสูญเสียของชุดตรวจสอบความถูกต้อง (Validation Loss) ต่ำที่สุด

4.3 ผลการประเมินประสิทธิภาพบนชุดข้อมูลทดสอบ

หลังจากได้จำนวนรอบการฝึกที่เหมาะสมแล้ว แบบจำลองแต่ละสถาปัตยกรรมถูกฝึกใหม่โดยรวมชุดข้อมูลสอนและชุดตรวจสอบความถูกต้องเข้าด้วยกัน คิดเป็นร้อยละ 80 ของข้อมูลทั้งหมด และใช้ชุดทดสอบร้อยละ 20 จำนวน 518 ภาพสำหรับประเมินประสิทธิภาพ โดยดำเนินการทดลองซ้ำจำนวน 5 ครั้งด้วยค่าเริ่มต้นการสุ่มที่แตกต่างกัน ผลการทดลองรายงานในรูปค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน แสดงได้ดังตารางที่ 5

ตารางที่ 5 ผลการประเมินค่าความถูกต้องบนชุดข้อมูลทดสอบ

แบบจำลอง	จำนวนรอบการฝึก	ค่าความถูกต้อง (Accuracy)
EfficientNetB0	86	93.94 ± 0.23%
ResNet50	59	93.82 ± 0.82%
DenseNet121	79	89.85 ± 0.75%

ผลการทดลองพบว่า EfficientNetB0 ให้ค่าความถูกต้องเฉลี่ยสูงที่สุดที่ร้อยละ 93.94 ± 0.23 รองลงมาคือ ResNet50 ที่ร้อยละ 93.82 ± 0.82 โดยมีผลต่างกันเพียง 0.12 จุด แสดงให้เห็นว่าทั้งสองแบบจำลองมีประสิทธิภาพในการจำแนกใกล้เคียงกันมาก ขณะที่ DenseNet121 ให้ค่าความถูกต้องเฉลี่ยร้อยละ 89.85 ± 0.75 ซึ่งต่ำกว่าอีกสองแบบจำลองประมาณ 4 จุด

นอกจากนี้ EfficientNetB0 มีส่วนเบี่ยงเบนมาตรฐานต่ำที่สุดที่ร้อยละ 0.23 เมื่อเทียบกับ ResNet50 และ DenseNet121 ที่ร้อยละ 0.82 และ 0.75 ตามลำดับ แสดงให้เห็นว่า EfficientNetB0 ให้ผลการจำแนกที่มี

*ภาควิชา---------- คณะ---------- มหาวิทยาลัย----------
* Department ----------, Faculty of ----------, University----------.
**ภาควิชา---------- คณะ---------- มหาวิทยาลัย----------
** Department ----------, Faculty of ----------, University----------.

ความสม่ำเสมอมากกว่าเมื่อทำการทดลองซ้ำด้วยค่าเริ่มต้นการสุ่มที่แตกต่างกัน

4.4 ผลการยืนยันประสิทธิภาพด้วยการตรวจสอบไขว้แบบ 5 ส่วน

เพื่อยืนยันความน่าเชื่อถือและความเสถียรของผลการทดลอง จึงได้ดำเนินการตรวจสอบไขว้แบบแบ่งชั้น 5 ส่วน (5-Fold Cross-Validation) และประเมินประสิทธิภาพด้วยค่าความถูกต้อง (Accuracy) ค่าความแม่นยำ (Precision) ค่าความไว (Recall) ค่าคะแนนเอฟหนึ่ง (F1-score) ค่าสัมประสิทธิ์แคปปาของโคเฮน (Cohen's Kappa) และค่าพื้นที่ใต้เส้นโค้ง ROC (ROC-AUC) ผลการทดลองแสดงในตารางที่ 6

ตารางที่ 6 ผลการประเมินด้วยการตรวจสอบไขว้แบบ 5 ส่วน

ตัวชี้วัด	EfficientNetB0	ResNet50	DenseNet121
Accuracy (%)	94.32 ± 0.51	94.43 ± 1.12	90.31 ± 1.26
Precision (%)	94.35 ± 0.51	94.42 ± 1.10	90.34 ± 1.23
Recall (%)	94.29 ± 0.51	94.40 ± 1.12	90.26 ± 1.26
F1-score (%)	94.29 ± 0.51	94.40 ± 1.11	90.25 ± 1.24
Cohen's Kappa	0.9242 ± 0.0068	0.9258 ± 0.0149	0.8708 ± 0.0168
ROC-AUC	0.9936 ± 0.0013	0.9927 ± 0.0029	0.9861 ± 0.0021

ผลจากการตรวจสอบไขว้แบบ 5 ส่วนให้แนวโน้มสอดคล้องกับผลการทดสอบบนชุดข้อมูลทดสอบ โดย ResNet50 มีค่าความถูกต้องเฉลี่ยสูงที่สุดที่ร้อยละ 94.43 ± 1.12 รองลงมาคือ EfficientNetB0 ที่ร้อยละ 94.32 ± 0.51 ซึ่งมีความแตกต่างกันน้อยมากจนไม่มีนัยสำคัญทางสถิติ ส่วน DenseNet121 ให้ค่าความถูกต้องที่ร้อยละ 90.31 ± 1.26 ผลต่างระหว่าง ResNet50 และ EfficientNetB0 มีเพียง 0.11 จุด แสดงให้เห็นว่าทั้งสองแบบจำลองมีประสิทธิภาพโดยรวมใกล้เคียงกัน

เมื่อพิจารณาความเสถียร EfficientNetB0 มีส่วนเบี่ยงเบนมาตรฐานของค่าความถูกต้องต่ำที่สุดที่ร้อยละ 0.51 เมื่อเทียบกับ ResNet50 ที่ร้อยละ 1.12 และ DenseNet121 ที่ร้อยละ 1.26 นอกจากนี้ EfficientNetB0 ยังมีค่า ROC-AUC สูงที่สุดที่ 0.9936 ± 0.0013 แม้ ResNet50 จะมีค่าความถูกต้องเฉลี่ยสูงกว่าเล็กน้อย จึงสะท้อนว่า EfficientNetB0 มีทั้งความสามารถในการแยกแยะประเภทและความสม่ำเสมอของผลลัพธ์ที่ดี

เมื่อเปรียบเทียบค่าความถูกต้องจากชุดทดสอบกับผลจากการตรวจสอบไขว้แบบ 5 ส่วน พบว่าค่าจากการตรวจสอบไขว้แบบ 5 ส่วนสูงขึ้นเล็กน้อย โดย EfficientNetB0 เพิ่มจากร้อยละ 93.94 เป็น 94.32, ResNet50 เพิ่มจากร้อยละ 93.82 เป็น 94.43 และ DenseNet121 เพิ่มจากร้อยละ 89.85 เป็น 90.31 หรือเพิ่มขึ้น 0.38, 0.61 และ 0.46 จุดร้อยละ ตามลำดับ ผลต่างที่ต่ำกว่า 1 จุด ในทุกแบบจำลองแสดงให้เห็นว่าผลจากทั้งสองวิธีการประเมินมีแนวโน้มสอดคล้องกัน

4.5 ผลการเปรียบเทียบเวลาในการฝึก

นอกจากประสิทธิภาพในการจำแนกแล้ว งานวิจัยนี้ยังพิจารณาเวลาในการฝึกของแต่ละสถาปัตยกรรม โดยภายใต้สภาพแวดล้อมการทดลองเดียวกัน พบว่า EfficientNetB0 ใช้เวลาเฉลี่ยประมาณ 0.47 นาทีต่อรอบการฝึก ResNet50 ใช้เวลาประมาณ 0.51 นาทีต่อรอบ และ DenseNet121 ใช้เวลาประมาณ 0.53 นาทีต่อรอบ แสดงดังตารางที่ 7

ตารางที่ 7 การเปรียบเทียบจำนวนรอบการฝึกและเวลาเฉลี่ยต่อรอบ

แบบจำลอง	จำนวนรอบการฝึกที่ใช้	เวลาเฉลี่ยต่อ Epoch
EfficientNetB0	86	≈ 0.47 นาที
ResNet50	59	≈ 0.51 นาที
DenseNet121	79	≈ 0.53 นาที

เมื่อพิจารณาเฉพาะเวลาในการประมวลผลต่อหนึ่งรอบ EfficientNetB0 ใช้เวลาต่ำที่สุด รองลงมาคือ ResNet50 และ DenseNet121 ตามลำดับ อย่างไรก็ตาม ResNet50 ต้องการจำนวนรอบการฝึกเพียง 59 รอบ ซึ่งต่ำกว่า EfficientNetB0 ที่ 86 รอบ และ DenseNet121 ที่ 79 รอบอย่างชัดเจน ดังนั้น แม้ ResNet50 จะใช้เวลาต่อหนึ่งรอบมากกว่า EfficientNetB0 เล็กน้อย แต่การลู่เข้าสู่จุดที่เหมาะสมด้วยจำนวนรอบที่น้อยกว่าถือเป็นข้อได้เปรียบในด้านเวลาในการฝึกโดยรวม ขณะที่

DenseNet121 ใช้เวลาเฉลี่ยต่อรอบสูงที่สุดและยังต้องใช้จำนวนรอบมากกว่า ResNet50

โดยสรุป ผลการทดลองแสดงให้เห็นว่า EfficientNetB0 และ ResNet50 ให้ประสิทธิภาพในการจำแนกใกล้เคียงกัน แต่มีคุณลักษณะเด่นแตกต่างกัน กล่าวคือ EfficientNetB0 มีความเสถียรของผลลัพธ์และเวลาเฉลี่ยต่อรอบที่ดี ขณะที่ ResNet50 สามารถลู่เข้าสู่จุดที่เหมาะสมด้วยจำนวนรอบการฝึกที่น้อยกว่า ส่วน DenseNet121 มีประสิทธิภาพในการจำแนกต่ำกว่าและใช้เวลาเฉลี่ยต่อรอบสูงกว่าอีกสองสถาปัตยกรรม

5. อภิปรายและสรุปผล

ผลการทดลองแสดงให้เห็นว่า EfficientNetB0 และ ResNet50 มีประสิทธิภาพในการจำแนกโรคใบข้าวใกล้เคียงกัน โดยเมื่อประเมินกับชุดข้อมูลทดสอบ EfficientNetB0 ให้ค่าความถูกต้องเฉลี่ยสูงสุดที่ร้อยละ 93.94 ± 0.23 ขณะที่ ResNet50 ให้ค่าร้อยละ 93.82 ± 0.82 ซึ่งแตกต่างกันเพียง 0.12 จุด ส่วน DenseNet121 ให้ค่าความถูกต้องต่ำกว่าที่ร้อยละ 89.85 ± 0.75 ผลดังกล่าวสะท้อนให้เห็นว่า แม้แบบจำลองทั้งสามจะใช้แนวทางการถ่ายโอนการเรียนรู้และถูกฝึกภายใต้เงื่อนไขเดียวกัน แต่ความแตกต่างด้านโครงสร้างของแต่ละสถาปัตยกรรมยังส่งผลต่อความสามารถในการสกัดคุณลักษณะและการจำแนกภาพ ซึ่งสอดคล้องกับงานของ Too และคณะ [3] ที่แสดงให้เห็นว่าสถาปัตยกรรมการเรียนรู้เชิงลึกที่แตกต่างกันสามารถให้ประสิทธิภาพในการจำแนกโรคพืชแตกต่างกันได้

เมื่อพิจารณาผลจากการตรวจสอบไขว้แบบแบ่งชั้น 5 ส่วน พบว่าแนวโน้มของผลลัพธ์สอดคล้องกับการประเมินบนชุดข้อมูลทดสอบ โดย ResNet50 ให้ค่าความถูกต้องเฉลี่ยสูงที่สุดที่ร้อยละ 94.43 ± 1.12 รองลงมาคือ EfficientNetB0 ที่ร้อยละ 94.32 ± 0.51 และ DenseNet121 ที่ร้อยละ 90.31 ± 1.26 ผลต่างระหว่าง ResNet50 และ EfficientNetB0 มีเพียง 0.11 จุด ขณะที่ EfficientNetB0 มีส่วนเบี่ยงเบนมาตรฐานต่ำกว่าและมีค่า ROC-AUC สูงที่สุดที่ 0.9936 ± 0.0013 แสดงให้เห็นว่า EfficientNetB0 มีความสม่ำเสมอของผลลัพธ์และความสามารถในการแยกประเภทของภาพที่ดี แม้ค่าความถูกต้องเฉลี่ยจะต่ำกว่า ResNet50 เล็กน้อยก็ตาม ผลดังกล่าวสอดคล้องกับแนวคิดของ EfficientNet ที่ออกแบบให้สามารถรักษาสมดุลระหว่างความแม่นยำและต้นทุนการคำนวณได้อย่างมีประสิทธิภาพ [5]

ในด้านพฤติกรรมการลู่เข้า พบว่า ResNet50 ใช้จำนวนรอบการฝึกที่เหมาะสมเพียง 59 รอบ ซึ่งต่ำกว่า EfficientNetB0 และ DenseNet121 ที่ใช้ 86 และ 79 รอบตามลำดับ ผลดังกล่าวแสดงให้เห็นว่าแต่ละสถาปัตยกรรมมีอัตราการลู่เข้าที่แตกต่างกัน และสนับสนุนแนวทางของงานวิจัยนี้ที่ใช้การหยุดก่อนกำหนดเพื่อค้นหาจำนวนรอบการฝึกที่เหมาะสมของแต่ละแบบจำลอง แทนการกำหนดจำนวนรอบการฝึกเท่ากันทุกแบบจำลอง เนื่องจากการกำหนดจำนวนรอบเท่ากันอาจทำให้บางแบบจำลองถูกฝึกน้อยเกินไปหรือมากเกินความจำเป็น การเลือกจำนวนรอบการฝึกจากค่าความสูญเสียของชุดตรวจสอบความถูกต้องจึงช่วยให้การเปรียบเทียบสะท้อนพฤติกรรมการเรียนรู้ของแต่ละสถาปัตยกรรมได้เหมาะสมยิ่งขึ้น

เมื่อพิจารณาประสิทธิภาพด้านเวลา EfficientNetB0 ใช้เวลาเฉลี่ยต่อรอบการฝึกต่ำที่สุดประมาณ 0.47 นาที รองลงมาคือ ResNet50 ที่ประมาณ 0.51 นาที และ DenseNet121 ที่ประมาณ 0.53 นาที อย่างไรก็ตาม ResNet50 ใช้จำนวนรอบการฝึกที่เหมาะสมน้อยที่สุดเพียง 59 รอบ จึงมีข้อได้เปรียบเมื่อพิจารณาความเร็วในการเข้าสู่จุดที่เหมาะสม ขณะที่ EfficientNetB0 แม้ต้องใช้จำนวนรอบมากกว่า แต่ให้ผลการจำแนกที่มีความเสถียรสูงกว่า ส่วน DenseNet121 ใช้เวลาเฉลี่ยต่อรอบสูงที่สุดและยังให้ประสิทธิภาพในการจำแนกต่ำกว่าอีกสองแบบจำลอง ดังนั้น การพิจารณาเลือกแบบจำลองสำหรับนำไปใช้งานจริงจึงไม่ควรพิจารณาเฉพาะค่าความถูกต้องเพียงอย่างเดียว แต่ควรพิจารณาร่วมกันทั้งความเสถียร จำนวนรอบการฝึก และเวลาในการประมวลผลด้วย

โดยสรุป งานวิจัยนี้แสดงให้เห็นว่า EfficientNetB0 และ ResNet50 เป็นแบบจำลองที่มีความเหมาะสม

สำหรับการจำแนกโรคใบข้าว 4 ประเภทภายใต้ชุดข้อมูลและเงื่อนไขการทดลองที่กำหนด โดย EfficientNetB0 มีจุดเด่นด้านความเสถียรของผลลัพธ์และเวลาเฉลี่ยต่อรอบที่ต่ำกว่า ขณะที่ ResNet50 มีจุดเด่นด้านการลู่เข้าสู่จำนวนรอบการฝึกที่เหมาะสมได้รวดเร็วกว่า ส่วน DenseNet121 ให้ผลการจำแนกต่ำกว่าและใช้ทรัพยากรด้านเวลามากกว่าเมื่อเทียบกับอีกสองแบบจำลอง ผลการศึกษายังชี้ให้เห็นว่าการใช้การหยุดก่อนกำหนดเพื่อกำหนดจำนวนรอบการฝึกที่เหมาะสมของแต่ละสถาปัตยกรรมเป็นแนวทางที่ช่วยให้การเปรียบเทียบแบบจำลองมีความเหมาะสมมากกว่าการกำหนดจำนวนรอบการฝึกเท่ากันทั้งหมด และสามารถใช้เป็นแนวทางในการเลือกแบบจำลองสำหรับพัฒนาระบบช่วยจำแนกโรคใบข้าวในอนาคตได้

6. เอกสารอ้างอิง

[1] J. Chotiko, "การพัฒนากระบวนการจำแนกโรคข้าวด้วย AI," depa Thailand. [Online]. Available: https://www.depa.or.th/th/article-view/ai-rice-disease. [Accessed: Sep. 14, 2026].

[2] M. Sharma, C. J. Kumar, and D. K. Bhattacharyya, “Machine/deep learning techniques for disease and nutrient deficiency disorder diagnosis in rice crops: A systematic review,” Biosystems Engineering, vol. 244, pp. 77–92, Aug. 2024, doi: 10.1016/j.biosystemseng.2024.05.014.

[3] E. C. Too, L. Yujian, S. Njuki, and L. Yingchun, “A comparative study of fine-tuning deep learning models for plant disease identification,” Computers and Electronics in Agriculture, vol. 161, pp. 272–279, 2019. doi: 10.1016/j.compag.2018.03.032.

[4] P. Seelwal et al., “A systematic review of deep learning applications for rice disease diagnosis: current trends and future directions,” Frontiers in Computer Science, vol. 6, Art. no. 1452961, 2024. doi: 10.3389/fcomp.2024.1452961.

[5] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," in Proceedings of the 36th International Conference on Machine Learning (ICML), Long Beach, CA, USA, 2019, pp. 6105-6114.

[6] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.

[7] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2017, pp. 2261-2269, doi: 10.1109/CVPR.2017.243.

[8] F. Zhuang, Z. Qi, K. Duan, D. Xi, Y. Zhu, H. Zhu, H. Xiong, and Q. He, “A comprehensive survey on transfer learning,” Proceedings of the IEEE, vol. 109, no. 1, pp. 43–76, Jan. 2021, doi: 10.1109/JPROC.2020.3004555.

[9] L. Prechelt, “Early stopping—But when?,” in Neural Networks: Tricks of the Trade, Berlin, Germany: Springer, 1998, pp. 55–69, doi: 10.1007/3-540-49430-8_3

[10] A. M, “Rice Disease Dataset,” Kaggle. [Online]. Available: https://www.kaggle.com/datasets/anshulm257/rice-disease-dataset. [Accessed: Jul. 14, 2026]